

Comparación del uso de Redes Neuronales Convolucionales para la clasificación de arritmias en señales ECG

Carlos Vásquez
Ingeniería Biomédica
Universidad Peruana
Cayetano Heredia
Email: carlos.vasquez@upch.pe

José Zapana
Ingeniería Biomédica
Universidad Peruana
Cayetano Heredia
Email: jose.zapana.g@upch.pe

Aldo Tecse
Ingeniería Biomédica
Universidad Peruana
Cayetano Heredia
Email: aldo.tecse@upch.pe

1. Introducción

Una arritmia es una irregularidad en el ritmo de los latidos del corazón: los latidos del corazón pueden ser más rápidos, más lentos o incluso con un ritmo irregular. La mayoría de arritmias son inofensivas, pero algunas pueden ser mortales. Por ejemplo, algunas arritmias como la fibrilación ventricular o la taquicardia puede significar un paro cardíaco o una muerte súbita. Asimismo, de acuerdo a la Organización Mundial de la Salud, las enfermedades cardiovasculares (ECV) produjeron aproximadamente 17.5 millones de muertes en 2012, el 30 % de las muertes globales [1]. Por otro lado, el costo del tratamiento de ECV en países de bajos a medianos ingresos ascenderá a US \$ 3.8 trillones desde el 2011 hasta el 2025 [1]. Justamente las detecciones tempranas pueden ayudar entonces, no solo a salvar vidas, sino a brindar estabilidad económica a los pacientes y sus familias.

El electrocardiograma (ECG) es una técnica de diagnóstico no invasiva y barata que ha sido utilizada durante más de 100 años desde su invención en 1893 [2]. El ECG representa la actividad eléctrica del corazón a lo largo del tiempo y contiene información fisiológica y patológica del corazón. Es por ello que puede ser utilizado para el diagnóstico de problemas cardíacos de arritmia. Generalmente se utilizan dispositivos médicos como un monitor Holter que tiene capacidades limitadas. Además, estas largas señales grabadas tienen que ser analizadas por cardiólogos expertos [3].

Por otro lado, gracias al rápido desarrollo de la tecnología, la información digitalizada de ECG es compleja y enorme. Por ejemplo, para el 2015 se estimaba que en todo el mundo se tenía 500 petabytes de información digital de salud y para 2020 se esperaba llegar 35 zettabytes [4], [5]. Teniendo en cuenta los efectos generados por pandemia de la COVID-19, los servicios de telemedicina se han incrementado en nuestro país, posiblemente acelerando el proceso de digitalización. Es por eso que nos centramos en revisar métodos basados en inteligencia artificial que son beneficiadas por la digitalización masiva de información y ayudar a los cardiólogos en su labor.

2. Metodología

La señal de ECG puede ser entendida mediante una serie de Fourier con varias frecuencias y ruido. El nivel de ruido es variable e incluso las ondas tienen diversas morfologías [6], [7]. Los modelos de aprendizaje profundo, especialmente las redes neuronales artificiales (ANN), son actualmente la forma más prometedora de superar estas limitaciones [8]. Según la revisión de la literatura de los algoritmos de segmentación de ondas de ECG en los últimos 10 años, existe una prevalencia de los enfoques basados en ANN sobre los métodos matemáticos clásicos. [9]. Las redes neuronales convolucionales (CNN) pertenecen al campo de aprendizaje profundo que utiliza operaciones convolucionales para reemplazar la multiplicación general [7]. Estas pueden extraer características discriminantes de mediante un proceso de entrenamiento y múltiples estudios han obtenido resultados bastante prometedores durante la segmentación de señales ECG basándose en algoritmos de CNN [10], [11], [12], [13], [14], [15].

2.1. Base de datos

Para comparar ambos métodos, se utilizó la base de datos MIT-BIH [16] que contiene señales ECG de 47 pacientes. Dentro de esta base de datos, se registraron 15 tipos de arritmia, se diferencian tanto por el cambio producido y el origen anatómico. Sin embargo, estas arritmias pueden ser agrupadas en cinco clases siguiendo las recomendaciones de Association for the Advancement of Medical Instrumentation (AAMI), ver la Tabla 3 [7] en el Anexo.

2.2. CNN con CWT e intervalos RR

El estudio realizado por Wang et al. se basa en analizar el espectro de frecuencia y las características de los intervalos RR. Esto se debe a que las arritmias usualmente afectan o producen un cambio en la forma del latido del corazón y, también, produce cambios alrededor de los intervalos RR. Además, como se mencionó anteriormente, podemos considerar la señal ECG como la suma de componentes

frecuenciales por lo que una alternativa para evitar el ruido es llevarlo al dominio de la frecuencia [7].

El diseño propuesto consta de 3 capas convolucionales con average pooling para la extracción de características de la CWT. La wavelet madre que se eligió es la "Mexican hat (mexh)", ya que es la que tiene un mayor parecido con la forma del complejo QRS. Luego se hace una fusión con las características de los intervalos RR en una capa completamente conectada (MLP), ver Figura 1. El modelo utiliza las clases de clasificación descritas en la Tabla 3 en el Anexo. En su publicación, los autores lograron una precisión de 98.74%, una sensibilidad de 67.47% y un F1-score de 68.76% [17].

2.3. Modelo basado en CNN-LSTM

Como se dijo previamente, las CNNs tienen una gran capacidad para separar patrones de cambios morfológicos en señales, a partir del cual adquiere grandes ventajas, como es tener una menor sensibilidad a señales ruidosas. Sin embargo, las señales biológicas son series temporales por lo cual recientemente ha tomado el interés de usar algoritmos que aprovechen esta característica, como son las redes neuronales recurrentes (RNN). Un tipo en particular son las capas LSTM, en donde el algoritmo circula por un bucle a través de tiempos adyacentes, a través de este tipo de iteración adquieren la capacidad de recordar u olvidar información de forma selectiva manteniendo un estado de memoria.

Oh et al. diseñaron una CNN con LSTM que tiene 6 capas convolucionales con average pooling, seguida de una capa LSTM de 20 unidades y 3 Fully Connected Layers, ver Figura 2. Este modelo cuenta con 5 clases, siendo cada una un tipo de latido arritmico. En su publicación, lograron una precisión global del 98.11%, una sensibilidad de 97.5% y una especificidad de 98.7% [17].

2.4. Procesamiento de señales

Se ha utilizado para ambos modelos un filtro que compense el desplazamiento de la línea base debido a la respiración o el movimiento del paciente. Siguiendo la metodología en [7], se adoptan dos filtros de mediana (es decir, un filtro de mediana de 200 ms de ancho y un filtro de mediana de 600 ms de ancho) para lograr la desviación de la línea de base, y luego restarla de las señales sin procesar para producir la corrección del desplazamiento de la línea base.

Para el modelo realizado en la Sección 2.2, la señal fue segmentada en pulsos de ECG tomados como 90 muestras antes de cada pico R y 110 muestras después de este pico. Por otro lado, para el modelo realizado en la Sección 2.3, se segmentó la señal en pulsos de ECG tomados como 99 muestras previas a un pico R y 160 muestras después del siguiente pico R. Para este segundo modelo, siguiendo la metodología propuesta por los autores [17], para homogenizar los segmentos, se definió que cada segmento debería contener 1000 muestras, substrayendo las primeras 1000 mues-

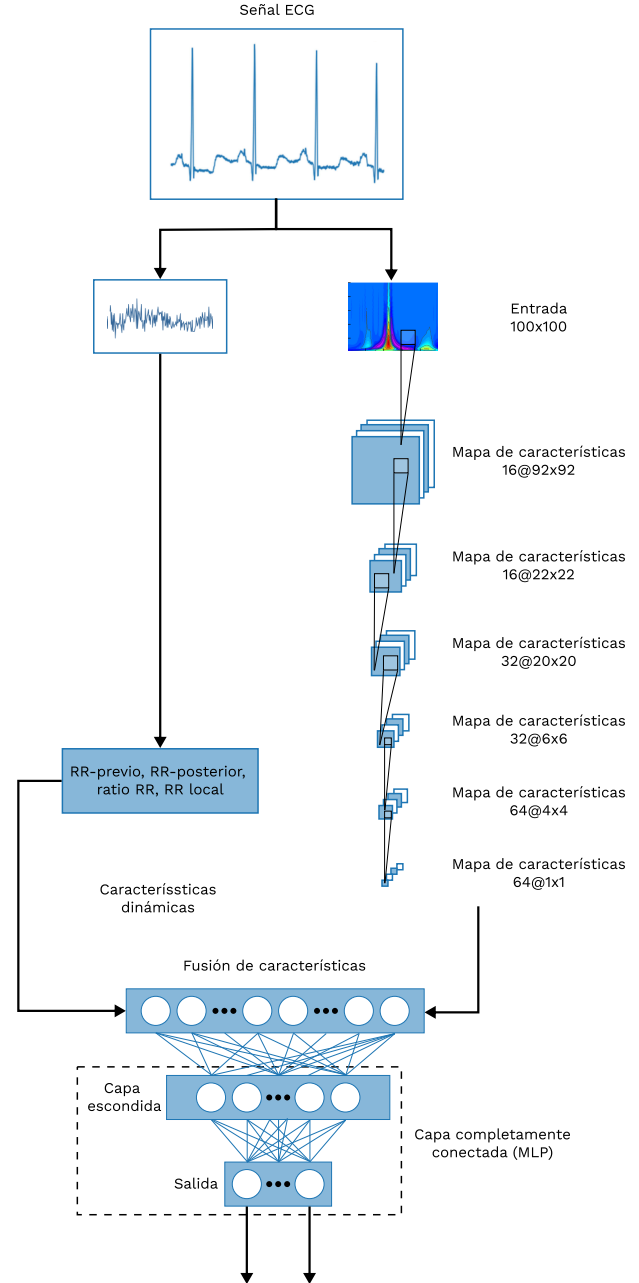


Figura 1. Modelo de CNN con CWT

tras a los segmentos que superen este valor, y agregando ceros a los segmentos con menos de 1000 muestras. Por otro lado, para ambos modelos se utilizó el mismo grupo de datos para los ensayos de predicción. Cabe aclarar que por cuestiones de homogeneización y obtener resultados comparables, se disminuyeron el número de clases de la última capa a 4, tomando en cuenta las clases utilizadas basado en lo descrito en la Tabla 3

Para poder realizar una comparación entre ambos modelos, se tomaron los mismos hiperparámetros para el entrenamiento de ambos modelos. Se estableció un tasa de




Figura 2. Modelo de CNN con LSTM

entrenamiento de 0.001 en conjunto con un optimizador Adam durante 30 épocas con un tamaño de batch de 1024, según lo definido por [7]

3. Resultados

Se obtuvieron los reportes de clasificación de ambos modelos con el fin de poder obtener las métricas de evaluación más comunes como la precisión, sensibilidad, F1-score, y compararlas entre sí. Las clases están definidas en la Tabla 3.

Tabla 1. RESULTADOS DE CNN CON CWT

-	Precisión	Sensibilidad	F1-score	Soporte
Normal	0.98	0.99	0.98	44218
SVEB	0.89	0.74	0.81	1836
VEB	0.93	0.95	0.94	3219
F	0.02	0.00	0.00	388
Precisión			0.97	49661
Promedio macro	0.70	0.67	0.68	49661
Promedio ponderado	0.97	0.97	0.97	49661

Tabla 2. RESULTADOS DE CNN-LSTM

-	Precisión	Sensibilidad	F1-score	Soporte
Normal	0.89	0.97	0.93	44218
SVEB	0.00	0.00	0.00	1836
VEB	0.14	0.06	0.08	3219
F	0.00	0.00	0.00	388
Precisión			0.87	49661
Promedio macro	0.26	0.26	0.25	49661
Promedio ponderado	0.80	0.87	0.83	49661

4. Discusión

Los resultados obtenidos en el Modelo CNN-LSTM comparados a lo obtenido en [17], presentan notables diferencias. Asimismo, comparado con los resultados del modelo de CNN-CWT, refleja que el modelo propuesto por [7], obtiene un mejor desempeño. Sin embargo, es importante tomar en cuenta que bajo el modelo propuesto por [17], se realizaba el entrenamiento del modelo bajo una diferente distribución de datos de entrenamiento, prueba y validación, subdividiendo los datos en 10 porciones equitativas, las cuales fueron entrenadas en 10 iteraciones. Asimismo, se realizaba el entrenamiento tomando en cuenta diferentes clases. Sin embargo, estas condiciones no fueron replicables bajo el hardware disponible en Google Colab.

Otro detalle importante es el desbalance de clases observado en los conjuntos de datos (entrenamiento y validación), esto pudo generar un sobre-entrenamiento para los datos de la clases predominante, ante lo cual el modelo no pudo recuperarse. En una futura iteración se buscará generar una distribución más homogénea, por medio de la incorporación de nuevas bases de datos, o fijando un límite superior al número de casos de cada clase.

Finalmente, al observar los reportes de clasificación de ambos modelos, se pudo determinar que el modelo CNN-CWT es mejor en virtualmente todas las métricas de evaluación, reconociendo mejor las diferencias entre cada clase.

References

- [1] K. Luo, J. Li, Z. Wang, and A. Cuschieri, "Patient-specific deep architectural model for ecg classification," *Journal of healthcare engineering*, vol. 2017, 2017.
- [2] G. Sannino and G. De Pietro, "A deep learning approach for ecg-based heartbeat classification for arrhythmia detection," *Future Generation Computer Systems*, vol. 86, pp. 446–455, 2018.
- [3] O. Yildirim, U. B. Baloglu, R.-S. Tan, E. J. Ciaccio, and U. R. Acharya, "A new approach for arrhythmia classification using deep coded features and lstm networks," *Computer methods and programs in biomedicine*, vol. 176, pp. 121–133, 2019.
- [4] J. Sun and C. K. Reddy, "Big data analytics for healthcare," in *Proceedings of the 19th ACM SIGKDD international conference on Knowledge discovery and data mining*, pp. 1525–1525, 2013.
- [5] H. Gui, R. Zheng, C. Ma, H. Fan, and L. Xu, "An architecture for healthcare big data management and analysis," in *International conference on health information science*, pp. 154–160, Springer, 2016.
- [6] I. Beraza and I. Romero, "Comparative study of algorithms for ecg segmentation," *Biomedical Signal Processing and Control*, vol. 34, pp. 166–173, 2017.
- [7] T. Wang, C. Lu, Y. Sun, M. Yang, C. Liu, and C. Ou, "Automatic ecg classification using continuous wavelet transform and convolutional neural network," *Entropy*, vol. 23, no. 1, p. 119, 2021.
- [8] Y. Xiang, Z. Lin, and J. Meng, "Automatic qrs complex detection using two-level convolutional neural network," *Biomedical engineering online*, vol. 17, no. 1, pp. 1–17, 2018.
- [9] A. Borde, "Intelligent decision support systems in cardiology," , vol. 23, no. 10, pp. 163a–163b, 2018.
- [10] M. Šarlija, F. Jurišić, and S. Popović, "A convolutional neural network based approach to qrs detection," in *Proceedings of the 10th international symposium on image and signal processing and analysis*, pp. 121–125, IEEE, 2017.
- [11] H. Yang, M. Huang, Z. Cai, Y. Yao, and C. Liu, "A faster r cnn-based real-time qrs detector," in *2019 Computing in Cardiology (CinC)*, pp. Page–1, IEEE, 2019.
- [12] S. Kiranyaz, T. Ince, and M. Gabbouj, "Real-time patient-specific ecg classification by 1-d convolutional neural networks," *IEEE Transactions on Biomedical Engineering*, vol. 63, no. 3, pp. 664–675, 2015.
- [13] P. Rajpurkar, A. Y. Hannun, M. Haghpahani, C. Bourn, and A. Y. Ng, "Cardiologist-level arrhythmia detection with convolutional neural networks," *arXiv preprint arXiv:1707.01836*, 2017.
- [14] S. Saadatnejad, M. Oveisi, and M. Hashemi, "Lstm-based ecg classification for continuous monitoring on personal wearable devices," *IEEE journal of biomedical and health informatics*, vol. 24, no. 2, pp. 515–523, 2019.
- [15] S. Hijazi, R. Kumar, C. Rowen, *et al.*, "Using convolutional neural networks for image recognition," *Cadence Design Systems Inc.: San Jose, CA, USA*, pp. 1–12, 2015.
- [16] G. B. Moody and R. G. Mark, "The impact of the mit-bih arrhythmia database," *IEEE Engineering in Medicine and Biology Magazine*, vol. 20, no. 3, pp. 45–50, 2001.
- [17] S. L. Oh, E. Y. Ng, R. San Tan, and U. R. Acharya, "Automated diagnosis of arrhythmia using combination of cnn and lstm techniques with variable length heart beats," *Computers in biology and medicine*, vol. 102, pp. 278–287, 2018.

5. Anexo

Tabla 3. MAPEO DE TIPOS DE ARRITMIAS EN MIT-BIH Y LAS CLASES DE LA AAMI

Clases de AAMI	Normal (N)	Latido supraventricular ectópico (SVEB)	Latido ventricular ectópico (VEB)	Latido fusionado (F)	Latido desconocido (Q)
Tipos de arritmia en MIT-BIH	Latido Normal (NOR) - N	Latido prematuro atrial (AP) -A	Latido de escape ventricular (VE) - E	Fusion de latido ventricular y normal (fVN) - F	Latido inclasificable (U) - Q
	Latido del bloqueo de la rama derecha del haz de His (RBBB) -R	Latido supraventricular ectópico o prematuro (SP) - S	Contracción ventricular prematura (PVC) -F		Fusión de un latido adelantado y normal
	Latido del bloqueo de la rama izquierda del haz de His (LBBB) - L	Latido prematuro nodal (NP) - J			Latido adelantado (P) - /
	Latido de escape atrial (AE) - e	Latido prematuro atrial aberrante (aAP) - a			
	Latido de escape Nodal (NE) - j				